
Analyse de l’agence des candidats à l’élection législative de 1993 par grands groupes politiques à partir de leurs professions de foi

Aurane Vernière
Ensaë PARIS,
Avril 2026

Abstract

L’étude des verbes dans une phrase, lorsqu’ils suivent un pronom personnel sujet, permet de répondre à la question de l’agence, ou du caractère actif, des locuteurs ou personnages des textes étudiés. Sous le prisme du genre, elle met en lumière les stéréotypes véhiculés par les auteurs, selon lesquels les femmes seraient moins actives que les hommes, ce qui se traduit lexicalement. Transposée à des textes politiques, ici les professions de foi de l’élection législative en France de 1993, cette étude vise à identifier si les candidats des différents bords politiques se présentent comme plus ou moins actifs. Le caractère actif est défini à la fois lexicalement parlant, en opposition aux verbes d’état, de cognition, de sentiment et par rapport au contexte de l’élection : est-ce qu’un candidat énonce des propositions concrètes ? En mobilisant des méthodes de *Natural Language Processing*, nous analysons les rôles et la fréquence des pronoms personnels dans les professions de foi par partis politiques et entraînons le modèle CamemBERT pour classer les verbes comme actifs ou inactifs selon les deux définitions données. Les candidats d’extrême-droite et écologistes apparaissent comme les plus actifs selon les deux acceptions. Tous les candidats se positionnent le plus fréquemment comme lexicalement actifs, mais les partis traditionnels, de gauche et de droite parlent autant du contexte électoral que des actions qu’ils mèneraient en tant qu’élus. Ces résultats restent à nuancer, du fait du trop faible nombre de données annotées.

1 Introduction

Les professions de foi sont des documents ayant pour but de diffuser aux citoyens l’argumentaire des candidats à une élection. Elles constituent ainsi des textes d’autopromotion où les candidats exposent les raisons pour lesquelles ils seraient compétents et ce qu’ils mettraient en oeuvre en tant qu’élus. Les possibilités d’analyse de ces textes sont multiples : étudier leur contenu, les sujets abordés, la manière dont les candidats construisent leur discours, s’ils font appel à des figures d’autorité, comment ils s’adressent à leurs électeurs, comment ils se mettent en valeur. En particulier, les textes des professions de foi, à l’image d’un discours, témoignent de la volonté d’agir du candidat. Cette dernière peut être caractérisée par ce qu’il exprime lorsqu’il parle en son nom, à travers les pronoms personnels *je*, *nous* et *moi* : les verbes employés à leur suite placent le sujet comme quelqu’un d’actif ou pas. Lexicalement parlant, nous définissons un verbe actif, par opposition aux verbes statifs, comprenant les verbes d’état, de cognition, d’expression des émotions, de réflexion et de sensation. Prenant en compte le contexte politique, un individu peut également être considéré comme actif s’il énonce des propositions concrètes, faites ou à faire en tant qu’élus, s’il montre qu’il

comprend les problèmes des citoyens. Au contraire, évoquer le contexte électoral, écrire des phrases creuses placent un-e candidat-e dans une posture politiquement inactive. Ce sont ces deux caractérisations de l’activité, ou agence, que nous nous proposons d’étudier en faisant appel aux méthodes du *Natural Language Processing*, pour les professions de foi de l’élection législative en France de 1993, issues des archives Archelec (GAULTIER-VOITURIEZ 2016). Nous répondrons à la question : *dans quelle mesure, les candidats des différents bords politiques, dans leurs professions de foi, se présentent-ils comme des personnes actives, au sens lexical ainsi qu’en termes politiques ?*

Nous mettons dans un premier temps en oeuvre les méthodes d’étiquetage morpho-syntaxique (ou *part of speech*), pour évaluer les fréquences d’usage des différents pronoms personnels d’intérêt, leur rôle dans la phrase et les verbes qui les suivent le plus fréquemment et comparons ces résultats entre groupes politiques. Nous avons ensuite procédé à l’annotation des *tokens* d’un ensemble de phrases où les candidats utilisent les pronoms *je* ou *nous* comme sujets, identifiant les verbes comme actifs ou non-actifs selon les deux définitions présentées. Nous avons ainsi créé deux labels et utilisons le modèle CamemBERT, pour apprendre les annotations, ce qui constitue une tâche de reconnaissance d’entités nommées et obtenir des prédictions par la suite.

Après avoir détaillé les différents résultats de la littérature, nous présentons la méthode mise en oeuvre en détaillant la manière dont nous avons annoté nos données, puis de premières statistiques descriptives sur les données utilisées. Enfin, nous présentons nos résultats et les discutons.

2 Revue de littérature

L’usage des pronoms constitue un pan de l’analyse des discours politiques, de la personnalisation de ces derniers et des méthodes d’adresses. Par exemple, BOUZEREAU et MAYAFFRE 2022 étudient les usages de différents pronoms personnels dans les discours politiques de ces dernières années, en se focalisant notamment sur le Front National. Ils confrontent l’usage du *nous* politique à celui plus personnel du *je* et moins précis du *on*. Ils soulignent notamment que l’usage du *nous* peut aussi bien avoir pour but de mettre en valeur une identité partisane qu’une volonté d’inclusion de la population dans son ensemble. DELMAS 2012 se concentre sur les discours de Nicolas Sarkozy lors de la campagne pour les élections présidentielles de 2007 et effectue une analyse des pronoms personnels utilisés, en notant que le *nous* dans ce cas ne renvoie à aucun collectif politique, mais permet au candidat de s’inscrire en tant que citoyen. Les verbes utilisés dans les discours sont aussi passés en revue, à travers les catégories de verbes d’opinion, locutoire, de sentiment et d’actions ; le rôle d’agent dans la phrase de Nicolas Sarkozy est exploré et il est relevé que le candidat se positionne rarement comme sujet actif et plutôt en tant qu’entité pensante. Dans ces deux cas, les textes analysés sont des discours politiques ; les professions de foi semblent au contraire être des documents politiques moins pris en considération dans la littérature d’analyse syntaxique et sémantique.

Si de nombreux articles de *natural language processing*, analysent les textes, discours politiques à travers la modélisation de sujet (*topic modeling*), la richesse lexicale, peu traitent de la personnalisation du discours et analysent le caractère actif du locuteur. Cette question a toutefois été traitée dans d’autres contextes : SAP et al. 2017 étudient les relations de domination et les différences d’agence entre personnages de films en se focalisant sur les structures sujet-verbe-objet ou le sujet et l’objet désignent deux personnes en interaction. Ils annotent alors les verbes transitifs de leur corpus selon les deux modalités, domination et agence et exploitent des méthodes de *natural language processing* pour mener à bien leur analyse. De manière similaire, STUHLER 2024 étudient les différences d’agence entre personnages féminins et masculins dans des textes littéraires. Ils se concentrent également sur les formes syntaxiques sujet-verbe-objet mettant deux agents, un homme et une femme, en interaction, et étudient la nature du verbe lorsque la femme ou l’homme est le sujet *ie* est agent. Ils utilisent les fonctionnalités de SpaCy, permettant entre autres la tokenisation,

l'étiquetage morpho-syntaxique, l'identification des dépendances. Ils optimisent cette dernière fonctionnalité en annotant un jeu de données, indiquant si les dépendances sont correctement identifiées par le *pipeline* ou ne le sont pas.

Les articles précédent exploitent des textes anglais et utilisent des modèles adaptés à cette langue. Pour la langue française, le modèle CamemBERT a été introduit par MARTIN et al. 2020 et accomplit des tâches de *part of speech tagging*, de reconnaissance d'entités nommées (NER), d'analyse de dépendances, et d'interprétation du langage naturel (NLI). Dans le cadre de la reconnaissance d'entités nommées, le modèle est évalué par ses auteurs sur le corpus arboré pour le français (*French Treebank*). Il a dans la suite par exemple été utilisé sur plusieurs corpus d'annotations du domaine médical (BANNOUR et al. 2024), ses performances ont été comparées à d'autres modèles de NER sur des corpus de textes littéraires et journalistiques (MILLOUR et al. 2024).

3 Méthode

L'analyse menée se déroule en deux étapes : d'abord une étude quantitative des pronoms utilisés parmi ceux d'intérêt, à savoir *je*, *nous* et marginalement *vous*, ainsi que leur rôle dans la phrase, à travers les verbes conjugués qui les suivent, grâce aux méthodes de *part of speech*. Plus précisément, nous avons utilisé les fonctionnalités de la librairie SpaCy : la tokenisation, la lemmatisation, afin d'identifier les verbes les plus couramment utilisés, le *part of speech tagging*, pour identifier la fonction des pronoms dans la phrase. Nous avons également utilisé l'identification des dépendances afin de calculer les fréquences auxquelles le pronom *vous* se rapportant aux électeurs était relié aux pronoms *je* ou *nous* se rapportant au candidat mais n'avons pas davantage approfondi cette approche.

Nous avons ensuite procédé à une étude plus approfondie du cas où le candidat parle de lui, à travers les pronoms *je* et *nous*, consistant en l'entraînement d'un modèle à partir d'un jeu de données annotées *token* par *token*. Pour cette deuxième étape, nous avons échantillonné des phrases des professions de foi avec les pronoms d'intérêts : après avoir effectué une première sélection naïve, nous nous sommes rendus compte que l'échantillon à annoter contenait d'une part des phrases apparaissant à plusieurs reprises, bien que nous ayons essayé de limiter ce phénomène et que les verbes associés aux pronoms d'intérêts étaient trop peu divers. Nous avons donc créé un deuxième échantillon complémentaire, en donnant préalablement un poids inversement proportionnel au nombre d'apparitions des verbes apparaissant à la suite de "*je*" et "*nous*" dans l'ensemble des professions de foi.

A travers l'annotation et l'entraînement d'un modèle, nous cherchons à étudier dans quelle mesure les candidats se présentent comme des personnes actives dans leurs professions de foi : d'une part d'un point de vue lexical – est-ce que les verbes employés lorsqu'ils parlent d'eux mêmes sont statifs ou actifs –, d'autre part d'un point de vue plus contextuel – est-ce que lorsqu'ils prennent la parole en leur nom, ils énoncent des actions concrètes déjà faites ou à faire. Nous avons donc créé deux labels, identifiant les verbes suivant les pronoms "*je*" et "*nous*" :

- Identifiant lexical : "B-VERB_ACT" et "B-VERB_ETAT" ;
- Identifiant du contenu du discours : "B-VERB_CONCRET" et "B-VERB_CONTEXTE".

Afin d'annoter de la manière la plus cohérente possible, nous avons convenu que les verbes annotés "B-VERB_ETAT" correspondraient à la catégorie des verbes statifs : les verbes d'état, de possession, d'expression des sentiments, de cognition. De même, les verbes annotés "B-VERB_CONCRET" doivent répondre à la question : est-ce que ce qui est énoncé fait référence à une action concrète déjà effectuée par la personne en tant qu'élue ou citoyen, à effectuer après son élection, ou à un problème qui affecte les électeurs au quotidien ? Ces deux catégories se ressemblent, l'exemple phare montrant néanmoins leur différence est lorsque le candidat écrit : "*Je me présente à l'élection...*". Le verbe *présenter* place le

candidat dans une position active, mais relève du contexte électoral et ne fait référence à aucune proposition concrète.

De plus, nous avons été amenés à raffiner ces annotations en adoptant le schéma BIO. En effet, cela s'est avéré nécessaire, d'abord pour différencier les enchaînements verbes de modalité-infinitifs : la formulation "*nous devons être des élus ...*" n'implique pas la même annotation pour les deux labels, que "*nous devons faire ...*". Pouvoir différencier certaines expressions verbales, par exemple *être à même de* contre *être le plus vigilant*, ou *baisser les bras* contre *baisser les charges*, a aussi motivé ce choix. Enfin, nous avons adopté la convention de ne pas annoter les auxiliaires, seulement le participe passé portant l'information du verbe. Nous avons pensé que cela ne serait pas une information trop compliquée à prendre en compte par le modèle, dans la mesure où les algorithmes de *part of speech tagging* réussissent à identifier les auxiliaires en les annotant 'AUX'.

Nous utilisons le modèle CamemBERT pour apprendre nos annotations, correspondant à une tâche de reconnaissance d'entités nommées.

4 Données

Nous travaillons sur les professions de foi d'une élection législative uniquement, celle de 1993 et avons pour objectif de comparer la manière dont se caractérisent les candidats des différents bords politiques. Le corpus contient au total 5837 professions de foi. De plus, le jeu de données ne comporte qu'une variable désignant le soutien du candidat titulaire, comprenant en général le parti politique et précisant la branche locale de ce dernier, si bien qu'à l'origine, 308 affiliations différentes sont encodées. De plus, en parcourant rapidement cette variable, nous constatons qu'il existe, en particulier pour les écologistes, un grand nombre de partis ou courants différents pouvant être regroupés sous une même étiquette plus générale. Nous avons donc créé une variable plus synthétique, associant à chaque candidat son bord politique. Pour cela, nous avons défini une liste de mots-clés pour chacun de ces bords et associé le candidat à la catégorie à laquelle correspond le mieux son affiliation initiale. On observe que le nombre de candidats écologistes domine (Table 1). Cela semble contre-intuitif, car les partis alors importants dans le paysage politique étaient ceux de droite (RPR, UDF...) et de gauche (PS) parlementaire. L'émergence du mouvement écologiste et la création d'une liste d'entente entre les groupes Les Verts et Génération écologie explique peut être le fait qu'un grand nombre de professions de foi aient été associées à ce courant.

Groupes politiques	
Autre / Non classé	306
Centre	121
Ecologiste	1084
Extrême-Droite	659
Extrême-Gauche	952
Parti socialiste - Gauche	481
Régionaliste	22
Sans étiquette / Divers	1243
UDF/RPR	969

TABLE 1 – Représentation des grands courants politiques au sein du corpus de professions de foi.

Voulant établir des statistiques sur l'emploi de certains mots, permettant de comparer les partis entre eux, il est important de s'assurer que le corpus de professions de foi ne contient pas pour un même parti des textes identiques ou très similaires. En effet, cela induirait ensuite un biais dans nos résultats : si par exemple une profession de foi utilisant beaucoup la première personne est reprise par beaucoup de candidats d'un même parti, la fréquence d'utilisation du pronom *je* apparaîtra artificiellement élevée. Nous identifions donc dans un premier temps le nombre de documents identiques par partis et très similaires, c'est-à-dire ayant une similarité cosinus supérieure à 90% (Table 2). Nous veillons dans la

Parti	Nb. textes	Nb. doublons exacts	Prop. paires similaires
Ecologistes	1084	34	0.17
Extrême-Gauche	952	16	0.06
Autre / Non classé	306	1	0.09
Extrême-Droite	659	0	0.01
Centre	121	0	0.01
Sans étiquette / Divers	1243	0	0.00
UDF/RPR	969	1	0.00
Parti socialiste - Gauche	481	0	0.00
Régionaliste	22	0	0.03

TABLE 2 – Nombre de professions de foi identiques et similaires à plus de 90% par groupes politiques.

suite, lorsque nous découpons les textes des professions de foi en phrases, de créer systématiquement une sous table de données contenant ces dernières de manière unique, parti par parti.

Voulant appliquer des méthodes de *part of speech* et de reconnaissance d'entité nommée, le nettoyage préalable des textes reste léger. Nous retirons principalement certains caractères spéciaux et des en-têtes ou annotations de bas de page, relatives à la source des archives. Nous veillons à ne pas retirer ni les accents, permettant de différencier par exemple le verbe *avoir* de la préposition *à*, ni la ponctuation, délimitant les phrases. Pour la prédiction d'entités nommées en utilisant le modèle CamemBERT, nous disposons d'un corpus de 628 phrases annotées à la main. La part de verbes annotés varie légèrement entre partis pour les deux labels, elle est comprise entre 46% et 62%, sauf dans pour l'extrême-droite, dans le cas du label "concret", qui compte 70% de verbes annotés (Tables 5 et 6).

5 Résultats

5.1 Etude quantitative de la personnalisation du discours par parti politique

Nous présentons les résultats issus de l'étiquetage morpho-syntaxique (POS) des données. Notre approche est d'abord quantitative : comparer la fréquence de l'emploi des pronoms d'adresse entre partis politiques, leur fonction dans la phrase et les verbes auxquels ils sont reliés.

On évalue d'abord la fréquence d'emploi des pronoms et déterminants possessifs par partis politiques (Figure 5). Si l'on n'observe pas de différences significatives entre partis, du fait des écarts types assez larges, il est intéressant de souligner que les partis pour lesquels le pronom *vous* et autres collocations est en moyenne plus fréquemment utilisé que les pronoms *nous* et *je* et déterminants possessifs associés, sont les extrêmes gauche et droite. Ceci peut traduire un discours ciblant davantage les électeurs, cherchant plus à les inclure, à les enrôler. Les candidats appartenant à des mouvances régionalistes emploient en moyenne plus fréquemment le pronom personnel *nous* : cela peut traduire d'une part une proximité renforcée entre le candidat et son électorat, les mouvances régionalistes mettant davantage l'accent sur les problématiques locales et la différenciation de leur territoire. De même, les écologistes emploient également en moyenne davantage ce pronom, ce qui peut aussi traduire un ancrage local, une volonté de réduire dans le discours la distance entre candidat et électeurs.

Nous restreignons ensuite notre étude aux seuls pronoms *je*, *nous* et *me* et étudions leur fonction dans la phrase. Nous nous intéressons surtout au cas où l'un des deux occupe la fonction de sujet et en représentons leur proportion parmi les pronoms du même type par parti politique (Figure 1). Pour tout les partis, cette dernière dépasse les 50% : elle est la plus basse pour le centre (67%) et la plus haute pour le parti socialiste (81%). Les différences entre partis ne sont pas suffisamment marquées pour en tirer des conclusions.

L'analyse morpho-syntaxique et de dépendances permet d'obtenir les formes infinitives des verbes suivant les pronoms d'intérêt ayant le rôle de sujet dans la phrase, par lemmatisation.




FIGURE 1 – Proportion de pronoms *je*, *nous* ou *me* étant sujets dans la phrase, parmi tous les pronoms du même type identifiés.

Il est alors possible d'extraire les verbes les plus fréquemment employés dans tout le corpus de textes et par partis politiques. Reviennent régulièrement des verbes de modalité, comme *pouvoir*, *devoir* ou *falloir* : si cela constitue une information en soi sur le mode d'expression des candidats, il est également informatif d'identifier les verbes infinitifs, qui généralement suivent ces verbes de modalités. En effet, "*nous devons nous présenter*" n'a pas le même contenu que "*nous devons défendre les plus faibles*". Nous procédons à cette extraction et représentons les contributions des candidats de chaque groupe politique pour chacun des dix verbes les plus fréquemment utilisés dans le corpus de texte en pondérant les résultats afin que les nombres différents de professions de foi par parti ne biaisent pas l'analyse (Figure 2).




FIGURE 2 – Les dix verbes les plus employés par les sujets *je* et *nous* du corpus de professions de foi, en extrayant les verbes vers lesquels pointent les verbes de modalité lorsque c'est nécessaire. Le verbe le plus employé se trouve à gauche. On représente les contributions des différents partis politiques, en pondérant pour ne pas tenir compte du nombre différent de profession de foi par parti. Légende : Rouge-UDF, Bleu ciel-Sans étiquette, Violet-Régionaliste, Beige-PS, Orange-Extrême-gauche, Rose-Extrême-droite, Vert foncé-Ecologistes, Vert clair-Centre, Bleu-Non classés.

Il ressort aussi bien des verbes de cognition comme *croire*, *savoir*, *connaître*, que des verbes d'action, comme *faire*, *défendre*, *proposer*. Le verbe le plus employé reste le verbe *avoir*, qui requiert un contexte pour mieux être compris. Par exemple, dans *avoir l'envie de faire*, le verbe n'a pas le même rôle que dans *avoir 30 ans* : dans le premier exemple l'expression suggère une position active, ce qui n'est pas le cas dans le second. Ceci motive l'idée d'annoter les verbes à la main, en adoptant le schéma BIO, pour différencier les structures verbe-préposition-infinitif, des structures verbe-nom. Les plus grandes contributions du groupe de candidats écologistes correspondent aux verbes *proposer* et *défendre*. L'extrême-gauche contribue grandement au verbe *dire*, également à *appeler* ou *faire*. Ces résultats laissent penser que les candidats de ces deux groupes se positionnent davantage comme des entités actives.

Cependant, cela n'est pas suffisant et nous extrayons aussi les cinq verbes les plus employés par parti politique, selon la même logique que précédemment, en cherchant le verbe racine pour les groupes verbe de modalité-verbe infini (Table 4). Du centre à l'extrême-gauche,

en incluant les écologistes, la volonté d'action politique semble marquée et se traduit par la présence des verbes *proposer* et *faire* parmi les trois verbes les plus fréquemment énoncés. De même pour les candidats sans étiquette. Nous rencontrons encore le verbe *avoir*, revenant souvent et dont la présence ne peut pas être interprétée.

5.2 Modèles de prédiction des types de verbes dans les professions de foi

Nous avons annoté selon les deux labels, identifiants lexical et du contenu du discours, 628 phrases différentes : nos échantillons d'entraînement, de validation et de test contiennent respectivement 501, 61 et 66 phrases. Nous utilisons le modèle pré-entraîné "*camembert-base*", mieux adapté à de petits échantillons de données, pour apprendre nos labels. Pour ces deux derniers, nous aboutissons au même réglage des hyper-paramètres, à savoir un *learning-rate* de $1e-4$, un nombre d'époques égal à 5, une taille de *batches* de 8 et un *weight decay* de 0.01. Nous pondérons également nos annotations inversement à leur fréquence d'apparition parmi toutes les phrases annotées. Nous obtenons alors des résultats contrastés : pour les deux types de label le modèle apprend bien les sujets (B-SUJ), les verbes en tête d'entités (B-VERB) et les mots non annotés (O), leurs F1-score sur l'échantillon de test étant proche ou supérieur de 0.8 (Tables 7 et 8). Les autres labels sont moins bien prédits du fait de leur moins grande fréquence d'apparition dans les données annotées.

Bien que les deux modèles soient critiquables par bien des points, nous les utilisons pour annoter tout le corpus de professions de foi et réaliser des statistiques descriptives, notamment utiles pour identifier les faiblesses de nos modèles.

On observe que les candidats d'extrême-droite, suivis des écologistes, des régionalistes et du centre, emploient en majorité des verbes, relatifs à des actions concrètes mises ou à mettre en place en tant qu'élus (Figure 3). Au contraire, les candidats d'extrême-gauche parlent plus fréquemment du contexte électoral et abordent moins les aspects concrets de leur programme, quand ils parlent comme sujets à travers les pronoms *je* ou *nous*. Pour les autres courants politiques, aucune des deux modalités du label relatif au contenu ("concret") ne dominant. De même, pour l'autre label, indiquant si le verbe place le sujet dans une posture active d'un point de vue strictement lexical, les candidats d'extrême-droite et écologistes sont ceux se présentant le plus fréquemment comme actifs (Figure 4). Les différences sont néanmoins moins marquées avec les autres partis politiques que pour le premier label, car tous les candidats des autres partis, à l'exception du centre, se positionnent comme actifs plus de 60% des fois où ils sont sujets des phrases qu'ils énoncent.




FIGURE 3 – Part des verbes prédits par le modèle portant les labels "B-VERB_CONCRET" (en bleu) et "B-VERB_CONTEXTE" (en orange) et suivant les pronoms *je* ou *vous*. Les résultats sont exprimés par groupes politiques.

S'agissant des verbes employés pour chacune des modalités des labels, on représente des nuages de mot par partis (Figures 7 et 8). Les verbes mis en valeur semblent cohérents avec leurs labels : on observe davantage de verbes d'état, de cognition ou d'émotion parmi ceux




FIGURE 4 – Part des verbes prédits par le modèle portant les labels "B-VERB_ACT" (en bleu) et "B-VERB_ETAT" (en orange) et suivant les pronoms *je* ou *vous*. Les résultats sont exprimés par groupes politiques.

annotés comme statifs par exemple, en comparaison aux verbes identifiés comme actifs. Les écologistes semblent avoir une rhétorique tournée vers les citoyens, car les verbes *réunir*, *proposer*, *défendre* apparaissent fréquemment ; de même pour les deux autres groupes de gauche, socialistes et extrême-gauche, emploient également régulièrement *défendre* et *proposer*. La particularité de l'extrême-gauche et la domination du verbe *faire* qui place les candidats à la fois comme lexicalement actifs et indique leur volonté de mettre en oeuvre des actions concrètes. Cette observation paraît légèrement contradictoire avec l'observation réalisée en comparant les simples statistiques d'annotation des verbes en début d'entité (Figure 3). L'extrême-droite est le seul groupe politique pour lequel les verbes *être* et *avoir* ne dominent pas comme verbes de contexte ou statifs : *vouloir* et *inquiéter*¹ reviennent régulièrement, caractérisant en partie l'expression de sentiments marqués.

Enfin, dans certains cas, un verbe ou deux dominent clairement, tandis que pour d'autres partis, comme le PS ou le centre, plusieurs verbes reviennent certes, plus régulièrement que les autres, mais ne semblent pas dominer drastiquement (Figure 7). Ceci peut découler d'un effet de présentation et n'est pas un résultat en soi, il faudrait l'appuyer par les fréquences effectives. On peut également supposer que le corpus de mots est moins important pour certains partis politiques et donc, par défaut, le rendu est moins dense pour ces derniers.

On retrouve également parmi les annotations un grand nombre de verbes de modalité et d'auxiliaires, peu informatifs malheureusement, ce qui semble cohérent avec les statistiques agrégées faites sur les fréquences d'apparition de verbes avec les méthodes de *part of speech*. Ceci découle du fait que l'on ne considère ici que les verbes en début d'entité, du type "B-VERB". Or, notre stratégie d'annotation consistait en l'annotation des groupes de verbes, notamment lorsque ceux-ci commençaient par un verbe de modalité, pour capturer toute l'information : le manque de verbes annotés à l'intérieur ou en fin d'entité ne permet pas d'avoir de bonnes prédictions sur ces derniers. Une solution momentanée pourrait être de ré-identifier à partir des transcriptions, les verbes suivant les verbes de modalité correctement prédits ici, mais cela semble trop coûteux en terme de code à implémenter. L'idéal reste que le modèle apprenne les bonnes formes verbales, ce qui n'est pas encore le cas.

6 Discussion

6.1 Procédure d'annotation des phrases

Notre procédure de sélection d'un corpus à annoter laisse à désirer : nous avons notamment dû échantillonner deux fois un ensemble de phrases, afin de prendre en compte les fréquences d'apparition des verbes. De plus, bien que nous ayons essayé de limiter ce phénomène, les

1. L'absence de forme verbale ici peut avoir deux explications : une erreur de lemmatisation ou l'annotation de ce sentiment comme début d'entité dans la forme verbale *être inquiet*.

échantillons à annoter comportent des phrases répétées, certaines professions de foi étant très similaires, voire identiques. Il est donc possible que nous en ayons annoté plusieurs fois la même phrase sans nous en rendre compte. Nous avons néanmoins réussi à nettoyer l'échantillon annoté avant l'entraînement, pour ne pas considérer plusieurs fois une même phrase.

Par ailleurs, la manière dont nous avons choisi d'annoter nos données s'est avérée complexe. De nombreux verbes pris dans leur contexte peuvent pour les deux labels correspondre aussi bien à la première comme à la deuxième des modalités d'annotation. Bien que nous ayons pour la partie lexicale une définition assez précise des verbes statifs, il peut être difficile de classer certaines formes verbales : par exemple, dans "*je chercherais à oublier*", le verbe *chercher* place le locuteur dans une posture plutôt active, mais *oublier* est un verbe de cognition. Nous avons rencontré des problèmes similaires pour l'autre label. Aussi, pour étudier si un candidat évoque des actions concrètes à effectuer, un contexte auquel fait face les électeurs, ou énonce un discours non informatif, simplement relatif au contexte de l'élection – c'est à dire le fait d'aller voter, d'être opposé à d'autres candidats –, il aurait été sans doute plus pertinent et plus facile d'annoter les phrases avec un label binaire, vrai ou faux. En effet, le contexte de la phrase aide souvent à décider si un verbe est plutôt "concret" ou fait référence au "contexte".

6.2 Le modèle

Les courbes d'évolution de la fonction de perte lors de l'entraînement et de la validation montrent que l'apprentissage des annotations n'est pas satisfaisant (Figures 6b et 6a). En effet, la courbe d'entraînement est très bruitée. Cela peut signifier un sur-apprentissage, mais nous supposons qu'il s'agit plutôt de variations dues au *learning-rate* trop élevé. Une solution serait donc de diminuer ce dernier, d'augmenter la taille des *batches* ou d'augmenter le *weight decay* : cependant, notre échantillon d'annotations est trop petit et ces modifications entraînent une trop grande diminution des performances du modèles sur les annotations des verbes. Il serait donc préférable d'annoter plus de phrases, mais nous n'en avons pas eu le temps.

De plus, avoir un corpus d'annotations plus fourni aurait permis d'avoir plus d'entités annotées à l'intérieur (I) ou à la fin (E) d'un groupe d'entités. Avoir un bon score de prédictions sur ces dernières, permettrait d'obtenir des groupes de verbes faisant davantage sens, par exemple d'être en mesure de différencier entre eux les groupes de verbes commençant par vouloir, pouvoir, devoir. N'ayant pu considérer que les verbes en tête d'entités (B), les verbes de modalité sont parmi les plus fréquemment employés, mais sont moins informatifs que les entités qui les suivent. Nous aurions aimé idéalement, différencier directement un *vouloir défendre*, d'un *vouloir expulser* (de manière très caricaturale).

S'agissant des prédictions obtenues, nous avons constaté que le modèle annote parfois le pronom *me* lorsqu'il est accolé au verbe, où *j'* et ce, assez fréquemment. Nous avons nettoyé ces imperfections pour réaliser nos statistiques descriptives sur les verbes. Il serait intéressant de regarder si ce problème persiste avec un plus grand nombre de données. De plus, l'échantillon de test n'étant pas très grand, il nous est difficile d'être sûrs des résultats obtenus. Le modèle fait environ d'après les résultats, 20% d'erreurs de prédictions sur les labels des verbes dans le meilleur des cas : cela n'est pas satisfaisant si l'on veut réaliser des statistiques descriptives dans la suite. Il serait aussi intéressant de calculer ces erreurs de prédiction par partis politiques. Si le modèle se trompe bien plus pour un parti que pour un autre, du fait des verbes employés par les candidats, alors les résultats deviennent difficilement comparables.

6.3 Représentation des résultats

Comme une première visualisation des verbes prédits par nos labels nous avons adopté des nuages de mots. Si ces graphiques ont l'avantage d'être faciles à comprendre, nous sommes conscients que les couleurs et tailles des mots, bien qu'elles soient liées à leur fréquence d'apparition peuvent introduire un biais dans la compréhension et l'interprétation. Il serait

pertinent d'ajouter des résultats quantitatifs précis, indiquant les valeurs de fréquences d'apparition et la richesse lexicale pour commencer.

7 Conclusion

Les professions de foi semblent être un matériau peu étudié dans la littérature d'analyse de textes politiques, en comparaison aux discours. Or, ces documents permettent aux candidats de se présenter, d'exposer leur point de vue par écrit. Il s'agit de textes plus ou moins personnalisés, comme en atteste l'analyse des similarités montrant qu'un texte peut être réutilisé par plusieurs candidats d'un même parti. Nous avons malgré cela étudié grâce aux méthodes de *Natural Language Processing* la personnalisation du discours, en nous concentrant sur la manière dont se présentent les candidats à leurs électeurs à travers la question de l'agence : est-ce que les locuteurs des différents groupes politiques se présentent comme actifs ou non-actifs ? Il s'est d'abord agit de comparer l'usage des pronoms *je*, *nous* et brièvement *vous* entre partis politiques : l'extrême-droite et les régionalistes semblent en moyenne faire moins usage des pronoms personnels que les autres partis, mais cette différence n'est pas marquée. Grâce aux méthodes d'analyse morpho-syntaxique, nous comparons ensuite la part de ces pronoms comme sujet dans la phrase entre partis, sans constater de grande différence et réalisons une première étude des verbes qui suivent ces sujets. Le grand nombre de verbes de modalité et des auxiliaires *être* et *avoir*, peu informatifs seuls quant au contenu du discours, motive l'entraînement d'un modèle sur des annotations manuelles des textes.

Nous avons échantillonné puis annoté selon deux labels, exprimant l'activité du sujet dans la phrase aux sens lexical et politique, un ensemble de 628 phrases. Les meilleures prédictions des labels par le modèle CamemBERT que nous arrivons à obtenir sont inégales : si nous prédisons bien les sujets et verbes en tête d'entité, avec un F1-score supérieur à 0.7 voire 0.8, les prédictions des verbes à l'intérieur (I) ou à la fin d'une entité (E) ne sont pas satisfaisantes. Nous n'avons donc pas pu les exploiter. L'analyse des verbes en début d'entité fournit malgré cela des premiers résultats : l'extrême-droite est le bord politique dont les candidats énoncent le plus de verbes relatifs à des actions concrètes qu'ils mèneraient en tant qu'élu. Suivent ensuite le centre et les écologistes. Les candidats d'extrême-gauche sont les seuls à parler en majorité du contexte électoral. Cela ne les empêche cependant pas de se présenter dans leur discours le plus fréquemment comme lexicalement actifs, comme les candidats des autres bords politiques. La représentation des verbes les plus utilisés par les candidats des différents groupes politiques sous la forme de nuages, permet d'une part de s'assurer que les prédictions des labels ne sont pas trop aberrantes, d'autre part d'identifier leurs faiblesses. La lemmatisation n'a pas fonctionné pour certaines formes verbales et les auxiliaires *être* et *avoir* ainsi que les verbes *vouloir* ou *devoir* apparaissent fréquemment. Avoir à disposition les prédictions de l'ensemble du groupe de verbes permettrait de raffiner l'analyse. Il aurait donc été nécessaire d'annoter un plus grand nombre de phrases. Enfin, sans doute pour l'analyse du contenu politique aurait-il été plus simple et plus efficace d'annoter les phrases entières par des booléens et extraire a posteriori les verbes des phrases.

Références

- BANNOUR, Nesrine, Christophe SERVAN, Aurélie NÉVÉOL et Xavier TANNIER (mai 2024). “A Benchmark Evaluation of Clinical Named Entity Recognition in French”. In : sous la dir. de Nicoletta CALZOLARI, Min-Yen KAN, Veronique HOSTE, Alessandro LENCI, Sakriani SAKTI et Nianwen XUE, p. 14-21. URL : <https://aclanthology.org/2024.lrec-main.2/>.
- BOUZEREAU, Camille et Damon MAYAFFRE (2022). “Menaces sur le nous. De l’usage problématique des pronoms dans le discours politique français contemporain”. In : *Cahiers de praxématique* 77. mis en ligne le 01 janvier 2022, consulté le 23 avril 2026. DOI : 10.4000/praxématique.7778. URL : <http://journals.openedition.org/praxématique/7778>.
- DELMAS, Valérie (2012). “Pour une analyse pluridimensionnelle du discours : le discours politique”. In : *La linguistique* 48.1, p. 103-122. DOI : 10.3917/ling.481.0103. URL : <https://doi.org/10.3917/ling.481.0103>.
- GAULTIER-VOITURIEZ, Olivier (2016). “Archelec, les archives électorales de la Ve République, du papier au numérique”. In : *Histoire@Politique* 30.3, p. 213-220. DOI : 10.3917/hp.030.0213. URL : <https://doi.org/10.3917/hp.030.0213>.
- MARTIN, Louis, Benjamin MULLER, Pedro Javier ORTIZ SUÁREZ, Yoann DUPONT, Laurent ROMARY, Éric de la CLERGERIE, Djamé SEDDAH et Benoît SAGOT (juill. 2020). “CamemBERT : a Tasty French Language Model”. In : *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Sous la dir. de Dan JURAFSKY, Joyce CHAI, Natalie SCHLUTER et Joel TETREAULT. Online : Association for Computational Linguistics, p. 7203-7219. DOI : 10.18653/v1/2020.acl-main.645. URL : <https://aclanthology.org/2020.acl-main.645/>.
- MILLOUR, Alice, Yoann DUPONT, Karen FORT et Liam DUGNAN (mai 2024). “Unveiling Strengths and Weaknesses of NLP Systems Based on a Rich Evaluation Corpus : The Case of NER in French”. In : *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*. Sous la dir. de Nicoletta CALZOLARI, Min-Yen KAN, Veronique HOSTE, Alessandro LENCI, Sakriani SAKTI et Nianwen XUE. Torino, Italia : ELRA et ICCL, p. 17217-17224. URL : <https://aclanthology.org/2024.lrec-main.1495/>.
- SAP, Maarten, Marcella Cindy PRASETTIO, Ari HOLTZMAN, Hannah RASHKIN et Yejin CHOI (sept. 2017). “Connotation Frames of Power and Agency in Modern Films”. In : sous la dir. de Martha PALMER, Rebecca HWA et Sebastian RIEDEL, p. 2329-2334. DOI : 10.18653/v1/D17-1247. URL : <https://aclanthology.org/D17-1247/>.
- STUHLER, Oscar (2024). “The gender agency gap in fiction writing (1850 to 2010)”. In : *Proceedings of the National Academy of Sciences* 121.29, e2319514121. DOI : 10.1073/pnas.2319514121. eprint : <https://www.pnas.org/doi/pdf/10.1073/pnas.2319514121>. URL : <https://www.pnas.org/doi/abs/10.1073/pnas.2319514121>.

A Préparation des données

Parti	Mots-clés
PS-gauche	parti socialiste, ps, gauche, mouvement des citoyens, socialistes, socialiste
RPR	rassemblement pour la république, rassemblement pour la republique, rpr
UDF	union pour la démocratie française, union pour la democratie francaise, udf
Centre	mouvement démocrate, modem, centriste, centre des démocrates sociaux, nouveau centre, les centristes, agir, alliance centriste, centre, mouvement des réformateurs
Écologistes	vert, verts, écologie, ecolo, génération écologie, nature et animaux, région verte, écologiste, biosphère, generation ecologie, écologie les verts, ecologie les verts, ecologie
Extrême-Droite	front national, fn, mouvement national, jeunesse nationaliste, alsace d'abord, identitaire, patriote, trop d'immigrés la france aux français
Extrême-Gauche	lutte ouvrière, ligue communiste, npa, nouveau parti anticapitaliste, parti des travailleurs, trotskyste, alternative libertaire, parti communiste français, ligue communiste révolutionnaire, communistes, communiste
Régionaliste	corsica, breton, occitan, alsacien, basque, euskal, unitat catalana, union démocratique bretonne, udb, autonomie, indépendantiste, abertzale, corse, corsa, euskal alkartasuna, esquerra republicana de catalunya
Sans étiquette	sans étiquette, divers, indépendant, apolitique, aucun parti, non mentionné, non inscrit, hors des partis, société civile, libre, nan, sans parti politique, aucune formation politique

TABLE 3 – Mots clés utilisés pour identifier les groupes politiques des candidats à partir de la variable "titulaire-soutien" des données sur les professions de foi de l'année 1993.

B Analyse des pronoms




FIGURE 5 – Fréquence pour 1000 mots des pronoms *je*, *nous*, *vous* par parti politique.

Parti	Verbes les plus employés (nombre d'occurrences)				
Autre / Non classé	avoir (25)	faire (12)	proposer (10)	être (10)	savoir (8)
Centre	proposer (11)	avoir (9)	faire (5)	aller (4)	assurer (4)
Ecologiste	proposer (138)	avoir (66)	faire (54)	souhaiter (41)	vouloir (37)
Extrême-Droite	invite (24)	avoir (12)	désirer (9)	faire (9)	trouver (6)
Extrême-Gauche	faire (137)	proposer (97)	dire (96)	avoir (82)	entendre (70)
Parti socialiste - Gauche	proposer (96)	avoir (91)	faire (73)	souhaiter (66)	croire (60)
Régionaliste	avoir (6)	souhaiter (4)	demander (3)	vouloir (3)	proposer (2)
Sans étiquette / Divers	avoir (222)	faire (207)	proposer (165)	savoir (119)	appeler (110)
UDF/RPR	avoir (174)	faire (147)	placer (82)	proposer (81)	croire (76)

TABLE 4 – Cinq verbes les plus employés après les sujets *je* ou *nous* par parti politique avec leur nombre d'occurrences entre parenthèses. Les verbes infinitifs suivant les verbes de modalité ont préalablement été extraits et remplacent ces derniers.

C Modèles de prédiction des labels

C.1 Statistiques d'annotation par groupe politique

Groupe politique	Nombre total de mots	Nombre total de verbes annotés	Part de verbes annotés
Autre / Non classé	5222	2963	0.57
Sans étiquette / Divers	23781	13507	0.57
Extrême-Gauche	26458	12470	0.47
Parti socialiste - Gauche	11489	6641	0.58
Ecologiste	9257	5544	0.60
Centre	1703	912	0.54
UDF/RPR	17177	9499	0.55
Extrême-Droite	14743	10254	0.70
Régionaliste	294	172	0.59

TABLE 5 – Nombre et part des verbes annotés par groupes politiques pour le label "concret".

Groupe politique	Nombre total de mots	Nombre total de verbes annotés	Part de verbes annotés
Autre / Non classé	5182	2832	0.55
Sans étiquette / Divers	23795	13323	0.56
Extrême-Gauche	25132	11672	0.46
Parti socialiste - Gauche	11233	6298	0.56
Ecologiste	10210	6337	0.62
Centre	1831	934	0.51
UDF/RPR	17071	9335	0.55
Extrême-Droite	10542	5449	0.52
Régionaliste	316	191	0.60

TABLE 6 – Nombre et part des verbes annotés par groupes politiques pour le label identifiant l'agence lexicale du sujet.

	<i>Precision</i>	<i>Recall</i>	F1-score	Support
B-OBJ	0.50	1.00	0.67	12
B-SUJ	0.99	0.99	0.99	94
B-VERB_ACT	0.87	0.89	0.88	66
B-VERB_ETAT	0.64	0.82	0.72	34
E-VERB_ACT	0.10	0.20	0.13	5
E-VERB_ETAT	0.00	0.00	0.00	4
I-VERB_ACT	0.24	0.46	0.32	13
I-VERB_ETAT	0.35	0.47	0.40	15
O	0.99	0.98	0.98	2257
<i>Accuracy</i>			0.96	2500
<i>Macro average</i>	0.52	0.65	0.57	2500
<i>Weighted average</i>	0.97	0.96	0.97	2500

TABLE 7 – Résultats des prédictions du modèle sur l'échantillon test pour le label visant à identifier si un verbe place le locuteur dans une posture active, d'un point de vue lexical.

	<i>Precision</i>	<i>Recall</i>	F1-score	Support
B-OBJ	0.46	1.00	0.63	12
B-SUJ	0.99	0.98	0.98	83
B-VERB_CONCRET	0.74	0.88	0.81	33
B-VERB_CONTEXTE	0.75	0.88	0.81	50
E-VERB_CONCRET	0.27	0.50	0.35	8
E-VERB_CONTEXTE	0.40	1.00	0.57	2
I-VERB_CONCRET	0.43	0.76	0.55	21
I-VERB_CONTEXTE	0.29	0.75	0.41	8
O	0.99	0.96	0.98	1916
<i>Accuracy</i>			0.95	2133
<i>Macro average</i>	0.59	0.86	0.68	2133
<i>Weighted average</i>	0.97	0.95	0.96	2133

TABLE 8 – Résultats des prédictions du modèle sur l'échantillon test pour le label "concret".

C.2 Evaluation de la performance




FIGURE 6 – Evolution de la fonction de perte sur les échantillons d'entraînement (en bleu) et de validation (en rouge) au cours des $n = 5$ epochs d'entraînement. La figure de gauche correspond à l'entraînement pour le label "concret" et celle de droite pour le label "lexical". Dans les deux cas, on fixe le *learning-rate* à $1e - 4$.

C.3 Nuages de verbes




Figure 7 – Nuage des verbes revenant le plus souvent après les pronoms *je* ou *nous* dans les professions de foi et étant identifiés comme "B-VERB_CONCRET" (colonne de gauche) ou "B-VERB_CONTEXTE" (colonne de droite). Les résultats sont exprimés par partis politiques, les lignes correspondent dans l'ordre, de haut en bas à : sans étiquette/divers, autre/non classé, écologistes, UDF/RPR, extrême-droite, partisocialiste/gauche, extrême-gauche, centre et régionalistes.




Figure 8 – Nuage des verbes revenant le plus souvent après les pronoms *je* ou *nous* dans les professions de foi et étant identifiés comme actifs (colonne de gauche) ou statifs (colonne de droite). Les résultats sont exprimés par partis politiques, les lignes correspondent dans l'ordre, de haut en bas à : sans étiquette/divers, autre/non classé, écologistes, UDF/RPR, extrême-droite, parti-socialiste/gauche, extrême-gauche, centre et régionalistes.